

리튬이온 배터리 예측 성능 향상을 위한 시계열 데이터 증강 기법 유효성 연구

김동현, 황준화, 홍건교, 서동준*

*corresponding author

경북대학교

{kdhnim96, jhhwang1907, gun2399, *dongjunsuh}@knu.ac.kr

A Study on the Validity of Time-series Data Augmentation Method for Improving Lithium-ion Battery Prediction Performance

Donghyeon Kim, Junhwa Hwang, Geonkyo Hong, Dongjun Suh*

Kyungpook National University

요약

리튬이온 배터리의 정확한 잔여 수명 예측은 배터리의 신뢰성과 안정성 보장에 필수적이다. 현재 리튬이온 배터리의 잔여 수명 연구는 딥러닝 기반으로 수행되고 있으며 딥러닝 모델의 성능은 데이터의 수에 크게 의존한다. 리튬이온 배터리 데이터는 정교한 작동 및 장기간의 사이클링 실험을 통해 얻을 수 있어 데이터 획득에 많은 시간과 비용이 필요하다. 따라서 본 연구에서는 STL (Seasonal and Trend Decomposition Using Loess) 분해를 통한 데이터 증강 기법을 적용하여 리튬이온 배터리의 잔여 수명 예측 성능을 향상시키고자 한다. LSTM (Long Short-Term Memory)과 Transformer를 사용하여 실험을 진행하였으며 실험 결과 두 모델 모두 STL 분해 기법을 통한 데이터 증강이 리튬이온 배터리 잔여 수명 예측 성능 향상에 유효함을 확인하였다.

I. 서론

리튬이온 배터리는 높은 에너지 밀도와 낮은 자가방전율, 긴 유효수명을 갖는다는 장점이 있어 전기자동차 및 우주 장비 등 광범위한 분야에 사용되고 있다. 하지만, 충·방전 사이클을 반복할수록 용량이 감소하고 저항이 증가함에 따라 리튬이온 배터리의 성능은 저하된다. 이때 배터리 운용의 신뢰성과 안정성을 보장하기 위해 정확한 RUL (Remaining Useful Life) 예측과 지속적인 PHM (Prognostics and Health Management) 기법 개발이 요구된다.

리튬이온 배터리의 PHM 연구는 현재 딥러닝을 기반으로 수행되고 있으며 개발 초기 단계이다. 리튬이온 배터리 데이터는 정교한 작동 및 장기간의 사이클링 실험을 통해 얻을 수 있어 많은 시간과 비용이 필요하여 데이터 수집에 어려움이 있다 [1]. 공개된 리튬이온 배터리 데이터셋 또한 매우 한정적이며 딥러닝 모델 학습 시 적은 데이터 수로 인한 과적합 (Overfitting) 문제가 발생할 수 있어 모델의 일반화 성능 달성에 어려움이 있다. 따라서, 본 연구는 CALCE Battery Research Group에서 제공하는 배터리 노화 데이터에 시계열 데이터 증강 기법을 적용하여 리튬이온 배터리의 RUL 예측 성능을 향상시키고자 한다.

II. 본론

2-1. 시계열 데이터 증강

데이터 증강 기법은 CV (Computer Vision) 분야뿐만 아니라 시계열 데이터 분야에서 광범위하게 사용되고 있다. 하지만 시계열 데이터는 일반적으로 시간 종속적 특성을 가지고 있어 CV 분야의 Flipping, Cropping 등과 같이 단순한 데이터 증강 기법의 적용은 시계열 데이터의 특성을 충분히 반영하기 어렵다 [2]. 따라서 본 연구에서는 STL (Seasonal and Trend Decomposition Using Loess) 분해를 통해 시계열 데이터를 증강하고 증강 데이터의 원 데이터에 대한 설명력을 검증하여 신뢰성을 확보

할 수 있도록 하였다.

2-2. STL 분해

STL은 시계열 데이터를 비선형 관계를 추정하는 Loess 평활화 방법을 연속 적용을 통해 데이터의 가산적 분해를 수행하는 기법이다. 데이터의 각 지점에서 다항식을 사용한 Locally weighted regression을 적용한다. STL 분해는 데이터의 이상값이 추세와 계절성에 영향을 거의 주지 않아 분해된 요소에 대해 높은 신뢰성을 보장할 수 있다. 또한, 성분 분해 시 인접 시점의 결과를 독립적으로 처리하여 계절성이 특정 형식을 취하도록 제한하지 않는다. 따라서 STL 분해 기법은 광범위한 시계열에 적용 가능하며 다양한 샘플링 집합에 적용할 수 있다는 장점이 있다 [3]. STL의 적용으로 시계열 데이터는 Fig 1과 같이 원 데이터를 계절성 (s_t)과 추세 (τ_t), 잔차 (r_t)로 분해할 수 있다.




Fig 1. STL Results Using CS2_35 Dataset of CALCE

STL을 통해 분해된 시계열 데이터 x_t 는 다음 Equation 1과 같이 나타낼 수 있으며 각 항에 계수를 곱하여 데이터를 생성할 수 있다. 생성된 데이터에 대한 신뢰성을 검증하기 위해 원 데이터와 생성된 데이터 사이의 상관계수 r 이 0.9 이상을 만족하는 계수 값을 선정하여 생성하였다.

$$x_t = s_t + \tau_t + r_t \quad (1)$$

Table 1. Summary of CALCE Dataset

	CS2_35	CS2_36	CS2_37	CS2_38
Fresh capacity [Ah]	1.126	1.134	1.124	1.127
Cycle	882	936	972	996

Table 2. Performance on CALCE Dataset based on RMSE (%)

		CS2_35	CS2_36	CS2_37	CS2_38
LSTM	w/o Aug	7.253	8.492	6.891	7.384
	w/ Aug	5.886	7.752	6.567	5.328
Transformer	w/o Aug	5.165	4.716	6.591	6.990
	w/ Aug	4.258	4.584	3.582	6.736




Fig 2. Capacity Degradation of CALCE Dataset

2-3. 데이터 및 훈련 모델

실험에는 Table 1과 같이 CALCE Battery Research Group에서 제공하는 CS2_35, CS2_36, CS2_37, CS2_38 총 네 개의 데이터셋을 사용하여 진행하였다 [4]. 데이터 증강 기법의 유효성을 강화하기 위해 시계열 데이터에서 자주 쓰이는 LSTM (Long Short-Term Memory)과 Transformer를 사용하였다. LSTM은 기존 RNN (Recurrent Neural Network) 이 시점 간의 차이가 클수록 과거 정보에 대한 학습이 어려워지는 기울기 소실 (Vanishing Gradient) 문제를 해결하기 위해 개발된 모델로 현재 시계열 분야에서 널리 사용되고 있다 [5]. Transformer는 자연어 처리를 위해 개발된 모델로 문장 속 단어와 같은 순차 데이터 내의 관계를 추적해 맥락과 의미를 학습한다. 또한, 연관성에 초점을 맞춘 Attention mechanism을 사용하여 요소들 사이의 수학적 파악이 가능하고 병렬 프로세싱에 적합하여 모델의 빠른 실행 속도 및 높은 성능을 달성하였다 [6].

4. 실험 및 실험 결과

리튬이온 배터리의 고장으로 판단하는 EoL (End of Life) 지점은 정격 용량의 70%로 설정하였으며 Train data는 각 데이터의 EoL 지점 이전의 70%로 설정하였다. 학습을 통해 EoL을 예측하고 RMSE (Root Mean Squared Error)를 평가지표로 사용하였다. 실험은 총 5회 반복 시행하여 평균값을 최종 점수로 채택하였다.

실험 결과, 데이터 증강을 수행한 경우 RMSE 값이 LSTM에서 평균 1.12%p, Transformer에서 평균 1.08%p, 전체 평균 2.2%p의 성능 향상이 있었음을 확인할 수 있었다. Table 2는 학습 데이터 증강 유무에 따라 학습을 진행한 결과를 나타내었다.

III. 결론

본 연구에서는 리튬이온 배터리의 잔여 수명 예측 성능 향상을 위해 STL 분해를 통한 시계열 데이터 증강을 수행하였다. 데이터 증강 유·무에 따른 비교 분석 결과 데이터 증강을 수행한 모델의 잔여 수명 예측 성능이 전체 평균 2.2%p 향상된 것을 확인하였다.

추후 연구로는 분해 기반의 시계열 데이터 증강뿐만이 아닌 통계적 생성 기법 및 DGM (Deep Generative Model)을 통해 시계열 데이터의 시간 종속적 특성을 더욱 반영할 수 있는 모델을 개발할 예정이다.

ACKNOWLEDGMENT

본 연구는 정부(과학기술정보통신부, 교육부)의 재원으로 한국연구재단의 지원을 받아 수행되었음 (과제번호: 2021R1A5A8033165, 2021R111A3049503).

참 고 문 헌

- [1] Zhang, Ying et al. "Prognostics and health management of Lithium-ion battery using deep learning methods: A review." Renewable and Sustainable Energy Reviews 161 (2022): 112282.
- [2] Wen, Qingsong, et al. "Time series data augmentation for deep learning: A survey." arXiv preprint arXiv:2002.12478 (2020).
- [3] Cleveland, Robert B., et al. "STL: A seasonal-trend decomposition." J. Off. Stat 6.1 (1990): 3-73.
- [4] Pecht M. Battery data set. In: Calce. Maryland, MD: CALCE Battery Research Group; 2017
- [5] Hochreiter, Sepp et al. "Long short-term memory." Neural computation 9.8 (1997): 1735-1780.
- [6] Vaswani, Ashish, et al. "Attention is all you need." Advances in neural information processing systems 30 (2017).